


Tu Propio Laboratorio de IA

Guía definitiva para desplegar inteligencia artificial 100% local, privada y sin suscripciones.




La Revolución de la Soberanía Digital



Privacidad Absoluta

Lo que pasa en local, se queda en local. Cero fugas de información personal o datos corporativos sensibles.



Fin de las Suscripciones

El uso intensivo de agentes en la nube genera facturas sorpresa. En local, el costo marginal por token generado es cero.



Soberanía Digital


Control total sobre cuándo se actualiza el modelo, qué hardware se utiliza y cómo se comportan los agentes sin censura.



Cero Latencia de Red

Inferencia directa en tu máquina. La velocidad depende de tu hardware, no de la congestión del servidor en la nube.

El Stack Tecnológico



Capa 4 - La Interfaz

Open WebUI. La experiencia de usuario y gestión multi-modelo.

Capa 3 - El Cerebro

Modelos GGUF (Llama, Mistral, Gemma). La lógica y el conocimiento.

Capa 2 - El Motor

Ollama / Llama.cpp. La orquestación y el procesamiento de tensores.

Capa 1 - La Infraestructura

Podman + SystemD Quadlets. El aislamiento seguro.

Los Cimientos - Hardware

GPU Nvidia, NPU, CPU.

Contenedores Blindados: ¿Por qué Podman?



Docker

Demonio centralizado (Punto único de falla).

Requiere privilegios de administrador.

Riesgo de escalada si la IA ejecuta comandos de sistema.




Podman

Arquitectura Daemonless: Sin procesos en segundo plano vulnerables.

Ejecución Rootless: Los procesos generados por la IA no pueden tomar control del host.

Integración SystemD: Uso de Quadlets para arrancar nativamente con el sistema operativo sin enguarrar el host.

El Hardware Manda: Ecosistema y VRAM




```
> nvidia-smi -l 1 -i 0 -o 0
```

Monitoreo vital de carga y VRAM en tiempo real.


Matriz de Decisión: Ollama vs. Llama.cpp

Ollama



- **Enfoque:** Facilidad de uso, envoltorio en Go.
- **Gestión:** Estilo Docker (`pull`, `push`, `run`). Orquestación automática.
- **Ventaja:** Hot-swapping (cambio instantáneo) y API unificada. Ideal para usuarios que quieren resultados inmediatos.

Llama.cpp



- **Enfoque:** Rendimiento puro y control absoluto. C++ nativo.
- **Gestión:** Descarga manual de archivos GGUF.
- **Ventaja:** Cuantización manual, `fine-tuning`, control granular de hilos. Para exprimir cada gota del hardware.

Dominando el Motor desde la Terminal

```
> show info  
> show parameters
```

Uso: Revela arquitectura, longitud de contexto (tokens), temperatura y filtro Top K.

```
> set system
```


Uso: Define el rol base.
Ej: "Eres un experto desarrollador de Python..."

```
> set verbose
```


Uso: Muestra métricas críticas post-respuesta (latencia total y tokens generados por segundo).

Anatomía de un Modelo: Descifrando el Código

Mistral-7B-Instruct-v3.0-Q4_K_M.gguf



El Desafío de la Ventana de Contexto



¿Qué es la KV Cache?

La memoria de trabajo a corto plazo.

Cada instrucción, chat previo y nueva respuesta entra en este límite físico.


El Efecto Borrachera

Si System Prompt + Historial + Nueva Pregunta > Límite, el modelo sufre amnesia.

Olvida sus instrucciones iniciales y comienza a alucinar.

Reglas de Oro de la Memoria

1,000 tokens $\approx$ 100 MB RAM
 $\approx$ 600 palabras




Open WebUI: El Front-End Definitivo

Agnosticismo Multi-Motor: Ejecuta simultáneamente Ollama, Llama.cpp y llamadas a APIs externas.


Control de Acceso (RBAC):
Gestión integral de usuarios, grupos y permisos granulares en red local.

Organización Real:
Soporte nativo de carpetas para organizar chats y proyectos.



Accesibilidad:
Diseño responsivo y PWA instalable para acceder al laboratorio desde el móvil.

Arquitectura de Prompts y Modelos Customizados



Inyección a Nivel Carpeta

Define roles específicos para todos los chats en una carpeta (ej. Carpeta 'DevOps' fuerza salidas en código puro).

Model Builder

Un 'Type Expert' local, listo a un clic, sin reescribir prompts jamás.

Ampliando la Mente: Memoria Continua y Búsqueda Web



RAG Interno


El modelo extrae y guarda datos clave autónomamente durante la charla. Recupera este contexto en sesiones futuras para personalizar la interacción.

Integración Web

El modelo decide cuándo salir a internet para buscar datos en tiempo real.

Regla Crítica: Limitar estrictamente las fuentes de búsqueda web (máx. 3). El scraping masivo inunda la ventana de contexto y provoca amnesia.

Superpoderes: Herramientas en Python




Plug & Play

1. El LLM identifica una necesidad matemática o geográfica.
2. La IA genera el código de la herramienta invocando una API externa (ej. `Nominatim`).
3. Instalas el script generado en la interfaz de WebUI.
4. En la próxima consulta ('¿`Distancia a Valencia?`'), el modelo ejecuta la herramienta autónomamente.

Extensibilidad sin límites. Incrusta calculadoras, integraciones con `Excel` o `APIs locales` directamente en la interfaz.

Síntesis: Tu Laboratorio Soberano en Acción



Infraestructura Segura

Aislamiento rootless y arranque limpio vía Quadlets.

Fuerza Bruta y Cerebro

Hardware dedicado ejecutando cuantización optimizada.

Automatización Total

Memoria continua y extensibilidad sin fronteras.

El límite ya no es la tarjeta de crédito; es tu hardware y tu imaginación.